DATA LAKE

Pipeline lake-first: landing → Bronze Parquet → Silver, collector และ dbt projection

Product Card

รหัสเอกสาร	CARD-solo-data-lake
ฉบับ	0.1
วันที่	2026-10-11
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. สรุปคุณค่าในหนึ่งประโยค

2. ปัญหาและผู้ใช้เป้าหมาย

3. สิ่งที่ทำได้จริงตอนนี้

4. หลักฐานสถานะ

5. คุณค่าและจุดต่าง

6. ช่องว่างสำคัญ

7. คำตัดสิน

8. ขั้นต่อไป

การอนุมัติ

แหล่งข้อมูล

solo-data-lake — Product Card

1. สรุปคุณค่าในหนึ่งประโยค

รวบรวมข้อมูล (ข่าว ตลาด SEO งาน Telegram/Brave ไดอารี) เข้า lake แบบ landing → Bronze → Silver เพื่อให้วิเคราะห์ย้อนได้จากแหล่งเดียว

2. ปัญหาและผู้ใช้เป้าหมาย

ข้อมูลที่เก็บมาหลายแหล่งกระจัดกระจายและไม่มี lineage ผู้ใช้คือเจ้าของและ pipeline วิเคราะห์

3. สิ่งที่ทำได้จริงตอนนี้

- โมดูล `infra/scripts/data_lake/` (47 modules: ingest, storage, query, silver, product_adapter, run_* capture)
- discovery/opportunities scripts, collector Telegram/Brave, dbt projection
- เทสต์ 70 ไฟล์ และ CI 5 workflow

4. หลักฐานสถานะ

รายการ	ค่า
Stack	Python, Parquet, dbt
Commit	75 ครั้ง (2026-07-27 ถึง 2026-10-11)
ซอร์สโค้ด	124 ไฟล์ / 32342 บรรทัด
เทสต์	70 ไฟล์ (ไม่ได้รันในงานนี้)
CI	5 workflow
Deploy config	ไม่มี deploy config (ทะเบียนระบุ exception/local)
Live URL	ไม่มี

5. คุณค่าและจุดต่าง

- lake-first ทำให้ย้อนตรวจและสร้างผลิตภัณฑ์ข้อมูลต่อได้
- **[สมมติฐาน]** ขาย data product ได้ถ้ามีชุดข้อมูลที่มีคุณค่า

6. ช่องว่างสำคัญ

- โครงสร้าง `infra/...` เดิมคงไว้เพื่อให้ path ทำงาน อ่านยาก
- ข้อมูลจริงอยู่นอก repo; ไม่ยืนยันขนาดและความสดของข้อมูล **[ต้องยืนยัน]**

7. คำตัดสิน

`invest` — ฐานข้อมูลวิเคราะห์ของระบบ มีโค้ดและเทสต์มากที่สุดในกลุ่ม จะเปลี่ยนเป็น `showcase` หากเลิกเก็บข้อมูลหรือย้ายไปบริการ managed

8. ขั้นต่อไป

1. ยืนยันว่า CI 5 workflow รันผ่านจริง
2. จัดโครงสร้างให้พ้น path `infra/...` เมื่อพร้อม

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Product owner (Book Dev)	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `infra/scripts/data_lake/`, `infra/tests/data_lake/`, `infra/dbt/`